

# BENEMÉRITA UNIVERSIDAD AUTÓNOMA DE PUEBLA

#### **FACULTAD CIENCIAS DE LA COMPUTACIÓN**

INTRODUCCION A LA CIENCIA DE DATOS

M.C. JAIME ALEJANDRO ROMERO SIERRA

**UNIDAD 2: LIMPIEZA DE UNA BASE DE DATOS** 

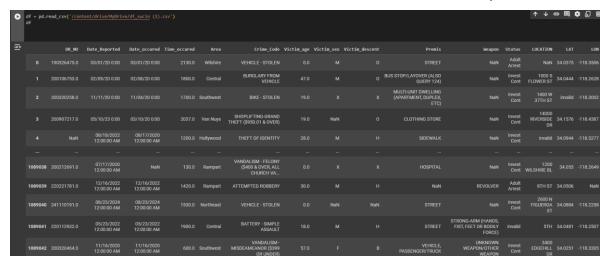
**ENSUCIADA** 

**ABRAHAM FUENTES LÓPEZ** 

22/10/2024

#### Análisis inicial:

#### Resumen estadístico de la base de datos antes de la limpieza



# Nuestro Dataframe cuenta con un total de 1,089,043 filas y 15 columnas:

```
# Resumen estadistico de la base de datos antes de limpiarse
# Cantidad de filas y columnas respectivamente
df.shape

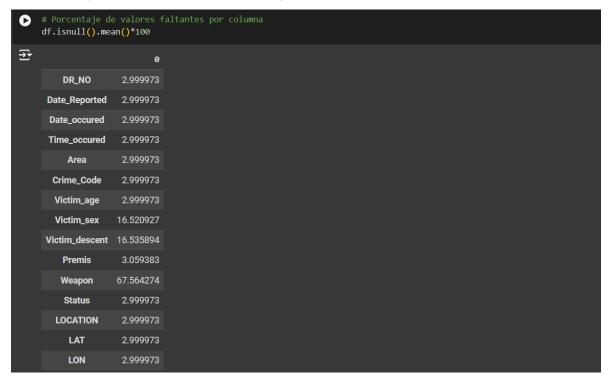
(1089043, 15)
```

#### Total de filas duplicadas:

```
# Total de filas duplicadas encontradas
df.duplicated(). sum()

38269
```

### Porcentaje de valores faltantes por columna:



# Descripción de los tipos de datos originales:

```
#Descripción de los tipos de datos originales.
 df.info()
<class 'pandas.core.frame.DataFrame'>
 RangeIndex: 1089043 entries, 0 to 1089042
 Data columns (total 15 columns):
  # Column Non-Null Count
                                                                     Dtype
  Ø DR_NO
                                  1056372 non-null float64
       Date_Reported 1056372 non-null object
        Date_occured 1056372 non-null object
Time_occured 1056372 non-null float64
        Area 1056372 non-null object
Crime_Code 1056372 non-null object
Victim_age 1056372 non-null float64
Victim_sex 909123 non-null object
   8 Victim descent 908960 non-null object

        9
        Premis
        1055725 non-null object

        10
        Weapon 353239 non-null object

        11
        Status 1056372 non-null object

        12
        LOCATION 1056372 non-null object

        13
        LAT 1056372 non-null object

        14
        LON 1056372 non-null object

                                     1056372 non-null object
 dtypes: float64(3), object(12)
 memory usage: 124.6+ MB
```

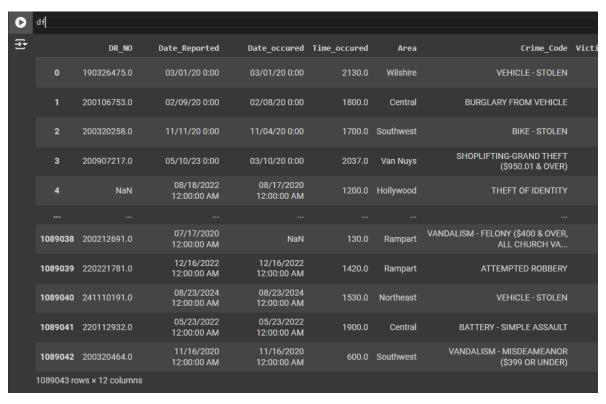
# Proceso de limpieza de datos

#### Eliminación de las columnas de LOCATION, LAT Y LON

No las ocuparemos ya que se usan para espacios geográficos específicos y aún no aprendemos a usar esas herramientas.

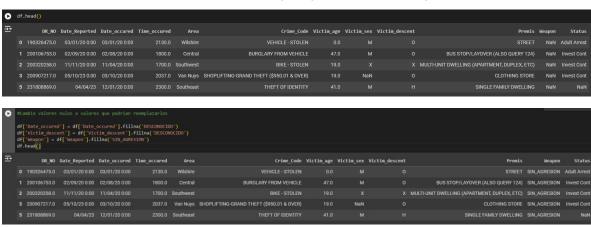


#### Eliminación de las filas con NaN de ciertas columnas

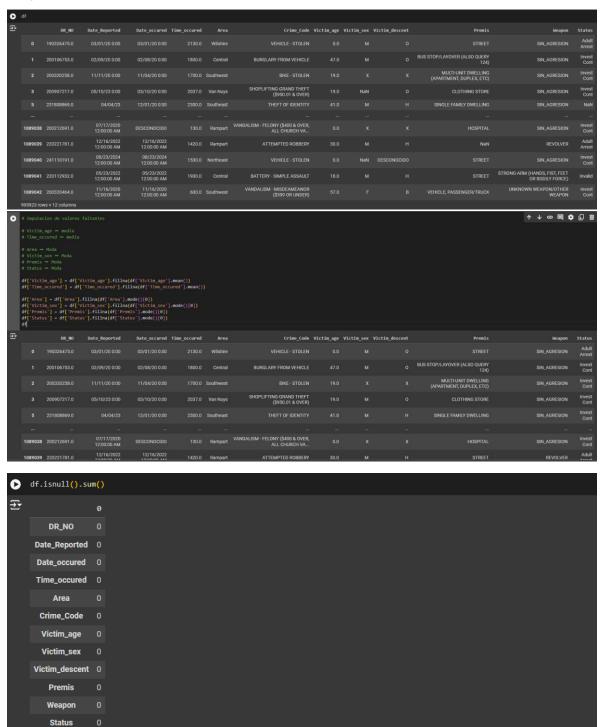


	<pre>#Elimina las filas con NaN de ciertas columnas  df = df.dropna(subset=['DR_NO'])  df = df.dropna(subset=['Date_Reported'])  df = df.dropna(subset=['Crime_Code'])  df</pre>							
<del>∑</del>		DR_NO	Date_Reported	Date_occured	Time_occured	Area	Crime_Code	Victi
	0	190326475.0	03/01/20 0:00	03/01/20 0:00	2130.0	Wilshire	VEHICLE - STOLEN	
	1	200106753.0	02/09/20 0:00	02/08/20 0:00	1800.0	Central	BURGLARY FROM VEHICLE	
	2	200320258.0	11/11/20 0:00	11/04/20 0:00	1700.0	Southwest	BIKE - STOLEN	
	3	200907217.0	05/10/23 0:00	03/10/20 0:00	2037.0	Van Nuys	SHOPLIFTING-GRAND THEFT (\$950.01 & OVER)	
	5	231808869.0	04/04/23	12/01/20 0:00	2300.0	Southeast	THEFT OF IDENTITY	
	1089038	200212691.0	07/17/2020 12:00:00 AM	NaN	130.0	Rampart	VANDALISM - FELONY (\$400 & OVER, ALL CHURCH VA	
	1089039	220221781.0	12/16/2022 12:00:00 AM	12/16/2022 12:00:00 AM	1420.0	Rampart	ATTEMPTED ROBBERY	
	1089040	241110191.0	08/23/2024 12:00:00 AM	08/23/2024 12:00:00 AM	1530.0	Northeast	VEHICLE - STOLEN	
	1089041	220112932.0	05/23/2022 12:00:00 AM	05/23/2022 12:00:00 AM	1900.0	Central	BATTERY - SIMPLE ASSAULT	
	1089042	200320464.0	11/16/2020 12:00:00 AM	11/16/2020 12:00:00 AM	600.0	Southwest	VANDALISM - MISDEAMEANOR (\$399 OR UNDER)	
	993923 rov	ws × 12 columns						

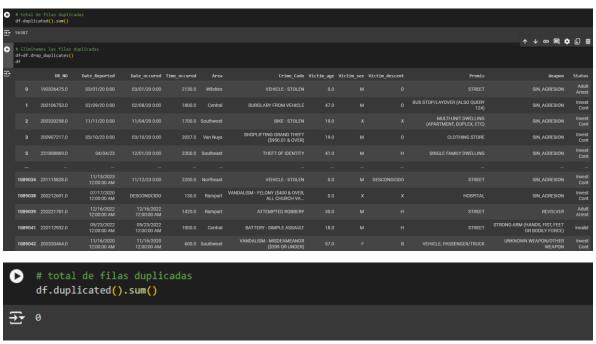
# Cambio valores nulos a valores que podrían reemplazarlos



# Imputacion de valores faltantes



# Eliminacion de las filas duplicadas



# Verificación y eliminación de invalid values

```
# Verificando si tenemos invalid values

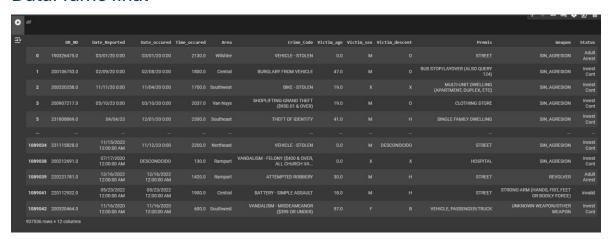
for i in lista_col:
    print(f"En la columna {i} los invalid_value son: {df[df[i] == 'bbb'].shape[0]}")

# NO tenemos invalid_value

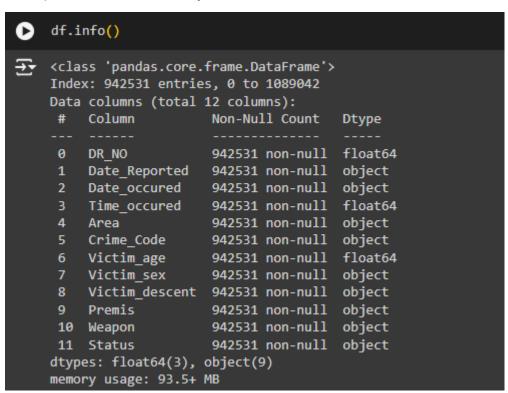
En la columna DR_NO los invalid_value son: 0
    En la columna Date_Reported los invalid_value son: 0
    En la columna Date_Reported los invalid_value son: 0
    En la columna Time_occured los invalid_value son: 0
    En la columna Time_occured los invalid_value son: 0
    En la columna Area los invalid_value son: 0
    En la columna (strim_ge los invalid_value son: 0
    En la columna (victim_ge los invalid_value son: 0
    En la columna Victim_sex los invalid_value son: 0
    En la columna Victim_sex los invalid_value son: 0
    En la columna Wictim_descent los invalid_value son: 0
    En la columna Weapon los invalid_value son: 0
    En la columna Status los invalid_value son: 0
    En la columna Status los invalid_value son: 0
```

#### Resultados de datos

#### DataFrame final



Nos quedan 937,536 Filas y 12 Columnas



Quedan 3 columnas de tipo float (numérico)

Tabla que muestre el porcentaje de valores faltantes final por columna.



Comprobación de que no hay duplicados ni valores inválidos.

```
## df.duplicated().sum()

## df.duplicated().sum()

## for i in lista_col:
    print(f"En la columna {i} los invalid_value son: {df[df[i] == 'bbb'].shape[0]}")

## En la columna DR_NO los invalid_value son: 0
En la columna Date_Reported los invalid_value son: 0
En la columna Date_occured los invalid_value son: 0
En la columna Time_occured los invalid_value son: 0
En la columna Area los invalid_value son: 0
En la columna Victim_ecode los invalid_value son: 0
En la columna Victim_age los invalid_value son: 0
En la columna Victim_sex los invalid_value son: 0
En la columna Victim_descent los invalid_value son: 0
En la columna Premis los invalid_value son: 0
En la columna Weapon los invalid_value son: 0
En la columna Status los invalid_value son: 0
```